服务路由

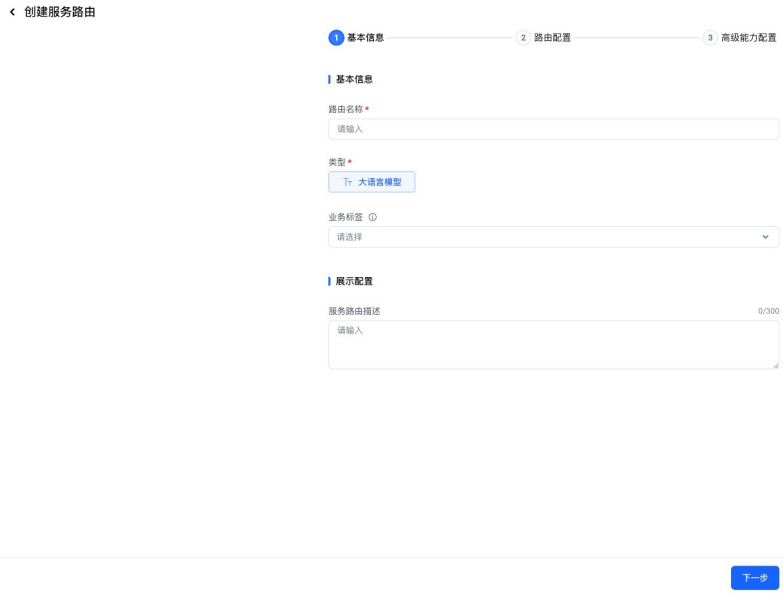
1. 空间服务路由

空间服务路由中支持创建当前空间的模型调用策略，多个模型服务按流量权重百分比进行调度。当配置的模型服务无法调用时，流量可进入备用模型服务。

仅大语言模型支持服务路由管理。

1.1 创建服务路由

1. 登录 HiAgent。
1. 在左侧导航栏，选择**模型 > 服务路由**。
1. 在服务路由管理页签，单击**创建服务路由**。
1. 填写配置项，单击**确定**。



基本信息

配置项	说明
基本信息	
路由名称	1. 必填 1. 自定义路由名称，与其他服务路由名称不能重复。 1. 长度【2,63】个字符。

类型	1. 必填 1. 默认大语言模型。
业务标签	1. 模型的辅助说明标签，配置后用户可在选择模型时查看。 1. 显示的标签在平台管理中的标签管理页面配置，初始列表： 1. 信息抽取 1. 内容创作 1. 角色扮演 1. 公开模型 1. 非公开模型
展示信息配置	
服务路由描述	1. 非必填 1. 支持 300 字描述。

路由配置

配置项	说明
模型服务配置	
路由模型服务	1. 必填 1. 在下拉框中选择模型服务，并输入流量权重。 1. 最多可添加 5 个路由模型服务，所有路由模型服务的流量权重总和为 100%。
Fallback 模型服务	1. 非必填 1. 如果配置的模型服务无法调用，流量将会进入备用模型服务。
高级能力配置	
调用方法	1. 自动勾选模型支持的调用方法。 1. 支持两种调用方法：Responses API、Chat Completions API。
高级能力	1. 自动开启所选模型支持的高级能力，多个模型显示高级能力交集。

	1. 大语言模型支持以下高级能力，部分高级能力配置项可手动配置。 1. Function Call 1. 图像理解 1. 视频理解 1. 音频理解 1. 文件理解 1. 深度思考 1. Reasoning Effort

高级能力配置

配置项	说明
大语言模型配置	
上下文窗口长度	1. 必填 1. 单次交互中（输入 + 输出）模型能容纳的总 token 数上限。 1. 系统自动给出所选模型的最大上下文长度，可手动修改。
最大输出 Token 长度	1. 必填 1. Agent 调用该模型时，单次回复的 max_tokens 配置项的最大值。 1. 系统自动给出所选模型的最大输出 Token 长度，也可以在下拉框中选择其他值（需小于配置的上下文窗口总长度）。
默认输出 Token 长度	1. 必填 1. Agent 调用该模型时，单次回复的 max_tokens 配置项的默认值。 1. 系统自动给出所选模型的默认输出 Token 长度，也可以在下拉框中选择其他值（需小于配置的上下文窗口总长度）。
最小输出 Token 长度	1. 必填 1. Agent 调用该模型时，单次回复的 max_tokens 配置项的最小值。 1. 系统自动给出所选模型的最小输出 Token 长度，也可以在下拉框中选择其他值（需小于配置的上下文窗口总长度，且小于默认值与最大值）。

模型信息	
参数	1. 必填 1. 可填写模型的参数信息：示例如下

```json
{
  "top_p": {
    "max": 1,
    "min": 0,
    "default": 0.7
  },
  "temperature": {
    "max": 1,
    "min": 0,
    "default": 1
  },
  "features": [
    "streaming",
    "stream-tool-call"
  ],
  "prompt": {
    "Role": "system",
    "ReactPrompt": {
      "Name": "flatten_cn_deepseek_r1_160",
      "EnableFewshots": false,
      "EnableInlineChatHistories": false,
      "RemoveStop": false,
    },
     "FunctionCall": {
        "EnableInlineChatHistories": false
    }
  }
}
```

1.2 服务路由管理

服务路由创建完成后，展示在服务路由列表中，支持以下操作：

1. **查看详情**：单击服务路由名称跳转至详情页查看详细配置。
1. **搜索**：支持按名称、ID 搜索服务路由。
1. **筛选**：支持按发布状态筛选服务路由。
1. **编辑：**操作栏单击编辑，进入编辑表单，可编辑基本信息、路由配置、高级能力配置。

1. **发布**：空间服务路由发布为租户级服务路由，授权可选择**公开**或**需授权**。
1. **下架**：下架后，此服务路由无法被其他空间调用，请谨慎操作。
1. **删除：**在需删除服务路由的操作列，单击**删除**。在跳出弹窗输入当前服务路由名称，即可删除。



2. 授权服务路由

授权服务路由页签展示授权给当前空间的服务路由。

1. **搜索**：支持按名称、ID 搜索服务路由。
1. **API 示例**：在服务路由操作列，单击 **API 示例**，支持查看 python、golang、java 示例。



梁瑾 2918