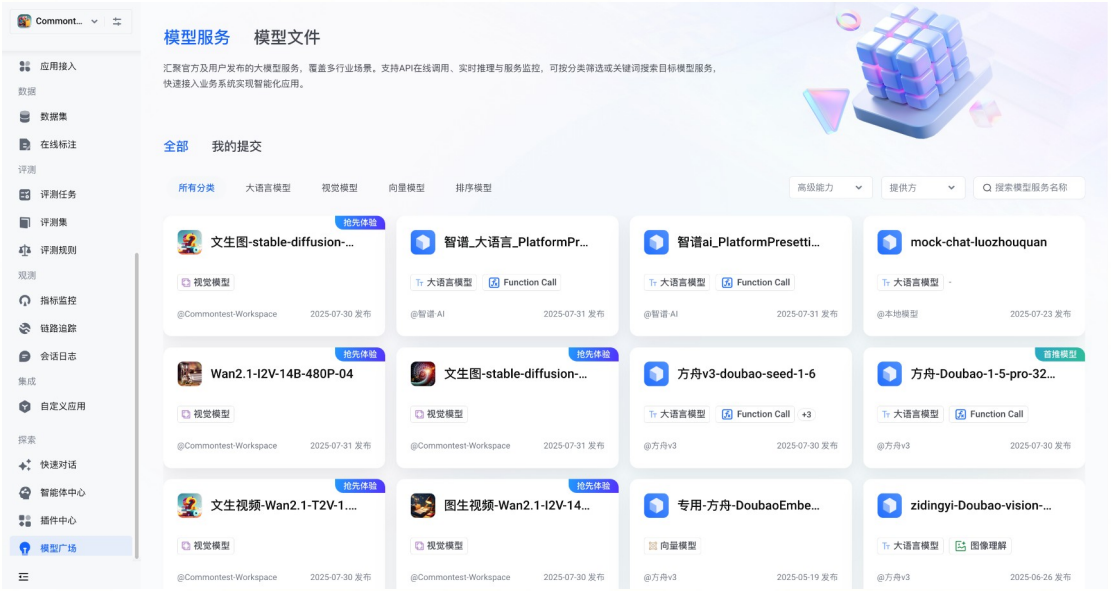
模型广场

1. 模型服务广场概述

汇聚官方及用户发布的大模型服务，覆盖多行业场景。支持 API 在线调用、实时推理与服务监控，可按分类筛选或关键词搜索目标模型服务，快速接入业务系统实现智能化应用。

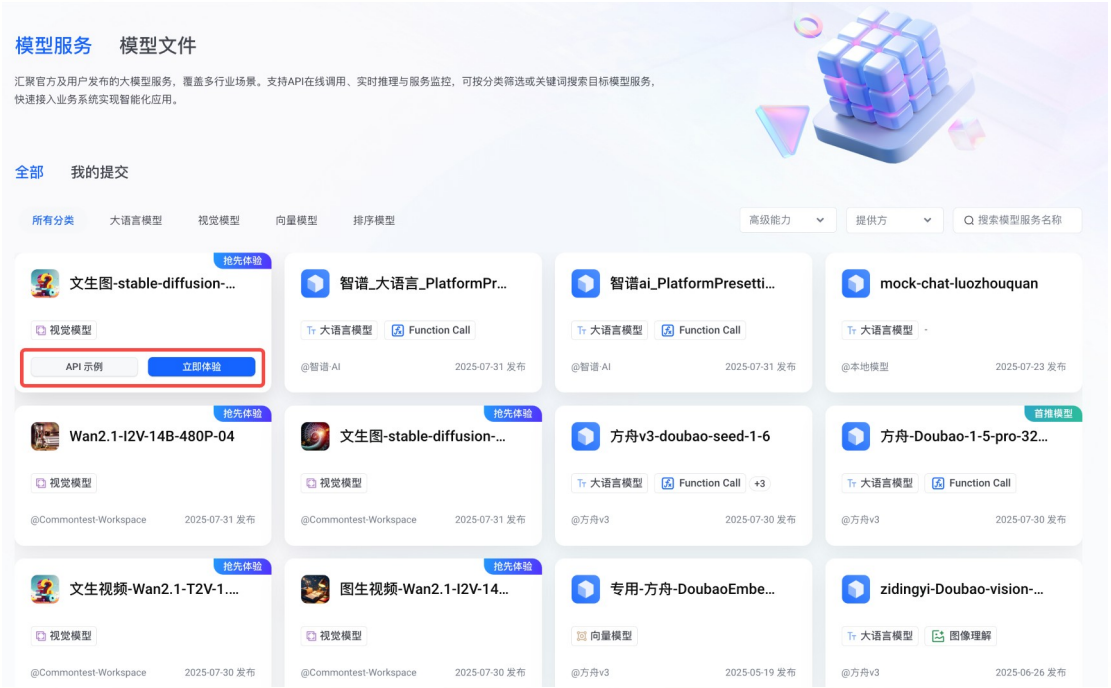
2. 模型服务列表

1. 模型服务广场中，每个模型卡片可查看模型服务的名称、Logo、提供方及基础介绍等。
1. 点击模型卡片进入详情页，查看更详细的说明信息。通过阅读文档深入了解模型的功能、性能和使用方法，根据自身业务需求判断选用哪些模型服务。



模型服务卡片可操作功能：

1. 鼠标放置任意模型服务卡片，点击 **API 调用**可查看模型的 API 调用示例。
1. 鼠标放置任意模型服务卡片，点击**立即体验**快捷方式进入模型服务对话页面。



3. 模型服务详情

1. 点击模型服务卡片进入模型详情页，详情页包含模型名称、模型状态、模型介绍和模型概览信息
1. 点击右上角 **API 示例**即可查看调用示例代码
1. 点击右上角**立即体验**即可进入模型对话页面



4. 模型文件广场概述

提供官方及用户调优的模型文件资源库，支持模型体验及部署。可通过分类检索或精准搜索获取模型，支持下载优化与二次训练，加速开发流程。

5. 模型文件列表

1. 模型文件广场中，每个模型卡片可查看模型的名称、Logo、提供方及基础介绍等。
1. 点击模型卡片进入详情页，查看更详细的说明信息。



模型文件卡片可操作功能：

1. 鼠标放置任意模型文件卡片，点击**模型部署**即可进入模型部署页面。
1. 鼠标放置任意模型文件卡片，点击**立即体验**快捷方式进入此模型对应服务对话页面。

6. 模型文件详情



选择模型文件卡片进入模型详情页，详情页包含模型名称、模型介绍和版本列表信息。

1. 单击右上角**模型部署**即可进入模型部署页面
1. 单击右上角**立即体验**即可进入模型文件对应服务的对话体验
1. 单击右上角**下架**即可下架模型


Qwen2.5-32B-Instruct-勿删-勿重复传
@Qwen ID d0jvujo0jsvosa3j9gv0 发布时间 2025-05-17 20:07:15
大语言模型
模型部署
立即体验
下架
模型介绍
版本列表
1.0
2025-05-17 20:07:15 发布
1.0
2025-05-17 20:07:15 发布 描述：-
推理配置
参数名 描述 类型 数值 默认值
temperature 采样温度，控制了生成文本时对每个候选词的概率分布进行平滑的程度。 Float 0-1 1
top_p 核采样概率阈值，模型会考虑概率质量在 top_p 内的 token 结果。 Float 0-1 0.7
top_k 选择预测值最大的 k 个 token 进行采样，取值范围 0-1000，0 表示不生效。 Int 0-1000 0
max_tokens 模型可以生成的最大 token 数量，输入 token 和输出 token 的总长度还受模型的上下文长度限制。 Int 0-4096 4096
max_prompt_tokens 最大输入 token 数，如果给出的 prompt 的 token 长度超过此限制，取最后 max_prompt_tokens ... Int 0-4096 4096
frequency_penalty 频率惩罚系数，如果值为正，会根据新 token 在文本中的出现频率对其进行惩罚，从而降低模型逐... Float -2-2 0
精调配置