观测指标接口

背景

HiAgent 平台提供将智能体作为后端服务 API 被业务请求的能力，用户希望获取平台内的指标数据作为导出，完成自身的特殊指标的后处理相关的需求。

调用步骤

1. 第一步：在平台内的密钥管理页面申请自己的 access key 和 secret key。
1. 第二步：使用对应的 sdk 对请求做签名。（具体可以参考 HiAgent 平台 API 调用示例）

API 列表概览（更多接口说明参考文档：数据统计接口.pdf）

接口名	描述
GetAgentMetricTokenCostByAgent	智能体 token 费用统计按智能体分类
GetAgentMetricTokenCostByInout	智能体 token 费用统计按 input output 分类
GetAgentMetricTokenCostByModelType	智能体 token 费用统计按模型类型分类
GetAgentMetricTokenCount	智能体 token 数量统计
GetAgentMetricTokenCountByModelType	智能体 token 数量统计按模型类型分类
GetAgentMetricTokenCountByAgent	智能体 token 数量统计按智能体分类
GetAgentMetricLatency	智能体延迟统计
GetAgentMetricQPS	智能体 QPS 统计
GetAgentMetricReqCount	智能体请求次数统计
GetAgentMetricReqSuccRate	智能体请求成功率统计
ListAgentMetricOverview	智能体指标概览

GetAgentMetricMessageOverview	智能体消息概览
GetAgentMetricMessageTrading	智能体消息趋势
GetAgentMetricChannelOverview	智能体渠道概览
GetAgentMetricChannelTrading	智能体渠道趋势
GetAgentMetricUserTrading	智能体用户趋势
GetAgentMetricConversationMessageNumTrading	智能体会话消息数趋势
GetAgentMetricUserRequestNumTrading	智能体用户请求数趋势
GetAgentMetricTotalView	智能体总览
GetAgentMetricAbnLatency	智能体异常分析，输出耗时
GetAgentMetricAbnTopLatency	智能体异常分析，输出耗时 top 10
GetAgentMetricAbnFailureRate	智能体异常分析，失败率
GetAgentMetricAbnTopFailureRate	智能体异常分析，失败率 top 10
GetAgentMetricAbnFailureTimes	智能体异常分析，失败次数
GetAgentMetricAbnSpanLatency	智能体异常分析，span 耗时
GetAgentMetricAbnSpanFailureRate	智能体异常分析，span 失败率
GetAgentMetricAbnSpanFailureTimes	智能体异常分析，span 失败次数
GetAgentMetricCostTop	智能体费用消耗 top
GetAgentMetricCostMsgTrading	智能体的消息的费用消耗趋势
GetAgentMetricCostUserTrading	智能体的用户的费用消耗趋势

GetAgentMetricCostChannelTrading	智能体费用渠道趋势
GetAgentMetricCostChannelOverview	智能体费用渠道分布
GetAgentMetricModelCostTrading	智能体对应的模型服务费用消耗趋势
GetAgentMetricModelCostTop	智能体对应的模型服务费用消耗 top
GetWorkflowMetricCostTop	工作流费用消耗 top
GetCustomAppMetricTokenRate	自定义应用 token 速率统计
GetCustomAppMetricTokenCost	自定义应用 token 费用统计
GetCustomAppMetricTokenCount	自定义应用 token 数量统计
GetCustomAppMetricTokenCountByModelType	自定义应用 token 数量统计按模型类型分类
GetCustomAppMetricLatency	自定义应用延迟统计
GetCustomAppMetricQPS	自定义应用 QPS 统计
GetCustomAppMetricReqCount	自定义应用请求次数统计
GetCustomAppMetricReqSuccRate	自定义应用请求成功率统计
ListCustomAppMetricOverview	自定义应用指标概览
GetCustomAppMetricMessageOverview	自定义应用消息概览
GetCustomAppMetricMessageTrading	自定义应用消息趋势
GetCustomAppMetricChannelOverview	自定义应用渠道概览
GetCustomAppMetricChannelTrading	自定义应用渠道趋势
GetModelMetricReqCount	模型请求数量统计
GetModelMetricReqSuccRate	模型请求成功率统计

GetModelMetricLatency	模型延迟统计
GetModelMetricActiveApp	模型活跃应用统计
GetModelMetricActiveSvc	模型活跃服务统计
GetModelMetricTokenCount	模型 token 数量统计
GetModelMetricTokenCountByModelType	模型 token 数量统计按模型类型分类
GetModelMetricTokenCountByModelSvc	模型 token 数量统计按模型服务分类
GetModelMetricResCPU	模型 CPU 使用统计
GetModelMetricResMemory	模型内存使用统计
GetModelMetricResGPU	模型 GPU 使用统计
GetModelMetricTokenRate	模型 token 速率统计
GetModelMetricMessageOverview	模型消息概览
GetModelMetricMessageTrading	模型消息趋势
GetModelMetricChannelOverview	模型渠道概览
GetModelMetricChannelTrading	模型渠道趋势
GetModelMetricTotalView	模型总览
GetModelMetricTokenCost	模型 token 费用统计
GetModelMetricTokenCostByModelType	模型 token 费用统计按模型类型分类
GetModelMetricTokenCostByModelSvc	模型 token 费用统计按模型服务分类
GetModelMetricTokenCostByInout	模型 token 费用统计按 input output 分类

GetModelMetricAbnLatency	模型异常分析，输出耗时
GetModelMetricAbnTopFirstTokenLatency	模型异常分析，首 token top 10
GetModelMetricAbnFailureRate	模型异常分析，失败率
GetModelMetricAbnTopFailureRate	模型异常分析，失败率 top 10
GetModelMetricAbnFailureTimes	模型异常分析，失败次数
GetModelMetricCostTop	模型服务费用消耗 top
GetModelMetricCostChannelTrading	模型服务费用渠道趋势
GetModelMetricCostChannelOverview	模型服务费用渠道分布
GetOperationMetricStatisticMap	运营端、平台管理端资源统计图表通用接口
GetOperationMetricStatisticMapWithGroup	运营端、平台管理端资源统计图表通用接口含有分组统计
GetOperationMetricStatisticTopk	运营端、平台管理端资源统计 topk 通用接口
GetOperationMetricDosageOverview	获取运营端用量概览
GetOperationMetricFlowOverview	运营端、平台管理流量分析概览
GetOperationMetricAgentOverview	智能体概览
GetOperationMetricPluginOverview	插件概览
GetOperationMetricWorkflowOverview	工作流概览
GetOperationMetricKwgDatasetOverview	知识库数据集概览
GetOperationMetricKwgDatabaseOvervi	知识库数据库概览

ew	
GetOperationMetricDatasetOverview	数据集概览
GetOperationMetricEvaOverview	运营端、平台管理评测概览
CreateOperationMetricExportAgent	运营端、平台管理 agent 导出任务创建
ListOperationMetricExportAgent	运营端、平台管理 agent 导出任务列表
CreateOperationMetricExportModel	运营端、平台管理 model 导出任务创建
ListOperationMetricExportModel	运营端、平台管理 model 导出任务列表
GetOperationMetricTableAgentOverview	运营端、平台管理 agent 表格数据
GetOperationMetricTableModelOverview	运营端、平台管理 model 表格数据

API 接口调用方式（具体可以参考 HiAgent 平台 API 调用示例）x 获取智能体 token 消耗数量（GetAgentMetricTokenCount）

1. 接口说明：针对智能体相关的 token 消耗的数量
1. 请求 header 说明（适用如下所有接口）：
    1. 请求 header 需要加上 Authorization，参考 HiAgent 平台 API 调用示例利用 sdk 的签名生成 Authorization。
    1. 请求 header 需要加上 `Content-Type: application/json`

POST /GetAgentMetricTokenCount

```
YAML
Url: {endpoint}/?Action=GetAgentMetricTokenCount&Version=2025-05-01
Method: POST
Query: Action=GetAgentMetricTokenCount&Version=2025-05-01
Header:
    "Content-Type": "application/json"
    "Authorization": "xxx"
Body:
    {
       "Aggregator": {
```

```
          "StartTime": "2026-03-06T05:54:23.983Z",
          "EndTime": "2026-03-09T05:54:23.983Z",
          "Step": 3600
        },
        "CommonFilter": {
          "AgentID": {
            "Value": ["xxx"], // 过滤指定的智能体 ID
             "Operator": "RawIn"
           }
          },
          "WorkspaceID": "personal-d2rh64ucckeegtm1ro70" // 智能体所
在的工作空间
       }

Response:
    {
      "ResponseMetadata": {
        "RequestId":
"021773035663504000000000000000000ffff0ae958e2e4a081",
        "Action": "GetAgentMetricTokenCount",
        "Version": "2025-05-01",
        "Service": "observe",
        "Region": "cn-north-1"
      },
      "Result": {
        "Data": {
          "completion": [ // 输出的 token 数量
             {
               "Time": "2026-03-06T08:00:00Z", // 对应时间点消耗的
token 数量
               "Value": 1962
             }
           ],
           "prompt": [ // 输入的 token 数量
             {
               "Time": "2026-03-06T08:00:00Z",
               "Value": 6951
             }
           ],
           "total": [ // 总的 token 数量
             {
               "Time": "2026-03-06T08:00:00Z",
               "Value": 8913
             }
```

```
            ]
        }
    }
}
```

梁瑾 2918